

TD 2

**EXERCICE 1.** En 2007, Netflix a lancé un des premiers gros *challenges* à l'ensemble des statisticiens, informaticiens et autre *data scientists*. Il s'agissait de battre leur propre algorithme de prédiction de préférence des utilisateurs, **Cinematch**. Grossièrement, les données sont un sous-ensemble des entrées d'une matrice  $M = (M_{i,j})_{1 \leq i \leq m, 1 \leq j \leq p} : M_{i,j} \in \{1, 2, 3, 4, 5\}$  est la note donnée par l'utilisateur  $i$  au film  $j$ . Il s'agit de reconstruire les entrées non observées. On propose la représentation suivante : on observe les entrées correspondant aux indices (supposés indépendants)  $X_1 = (i_1, j_1), \dots, X_n = (i_n, j_n) \sim \Pi$ . Ces entrées sont notées  $Y_\ell = M_{i_\ell, j_\ell}$ . Pour toute matrice  $N \in \{1, \dots, 5\}^{n \times p}$  on définit

$$R(N) = \mathbb{E}[(Y_\ell - N_{i_\ell, j_\ell})^2] = \sum_{i=1}^m \sum_{j=1}^p (N_{i,j} - M_{i,j})^2 \Pi((i, j))$$

et

$$r_n(N) = \frac{1}{n} \sum_{\ell=1}^n (Y_\ell - N_{i_\ell, j_\ell})^2.$$

Une hypothèse naturelle est qu'il existe un certain nombre, disons  $K \ll m, p$ , de comportements de base (amateurs de science-fiction, amateurs de cinéma russe...) et que les goûts de chaque utilisateur peuvent être approchés par une combinaison linéaire de ces goûts de base. On propose donc la loi  $\pi$  *a priori* suivante :

$$\underbrace{N}_{m \times p} = \underbrace{U}_{m, K} \underbrace{V}_{K, p}$$

où les entrées  $U_{i,h}$  et  $V_{h,j}$  sont i.i.d de loi  $\mathcal{U}([-\sqrt{c/K}, \sqrt{c/K}])$  avec  $c > 0$  constant. Noter qu'on a alors bien  $N_{i,j} = \sum_{h=1}^K U_{i,h} V_{h,j}$ , les  $(U_{1,1}, \dots, U_{m,1}), \dots, (U_{1,K}, \dots, U_{m,K})$  sont interprétés comme les  $K$  comportements de base. Pour tout  $\lambda > 0$  on pose

$$\hat{M}_\lambda = \int N \pi_{\exp(-\lambda r_n)}(dN).$$

Pour simplifier les notations, pour toute matrice  $H$  on notera  $\|H\| = \sup_{i,j} |H_{i,j}|$ .

- 1) Expliquer pourquoi, pour tout  $\lambda > 0$ ,

$$R(\hat{M}_\lambda) \leq \int R(N) \pi_{\exp(-\lambda r_n)}(dN).$$

- 2) Pourquoi serait-il déraisonnable de prendre  $c < 5$  ? On supposera donc que  $c \geq 5$ .
- 3) Vérifier que les variables aléatoires  $|(Y_\ell - N_{i_\ell, j_\ell})^2 - R(N)|$  sont bornées par  $4c^2$ .
- 4) En déduire que l'on a, pour tout  $\varepsilon > 0$ , avec proba. au moins  $1 - \varepsilon$ ,

$$R(\hat{M}_\lambda) \leq \frac{2 \vee \left(1 + \frac{4c^2\lambda}{n} g\left(\frac{8c^2\lambda}{n}\right)\right)}{1 - \frac{4c^2\lambda}{n} g\left(\frac{8c^2\lambda}{n}\right)} \inf_{\rho} \left[ \int R(N) \rho(dN) + \frac{\mathcal{K}(\rho, \pi) + \log\left(\frac{2}{\varepsilon}\right)}{\lambda} \right]$$

où  $g$  est la fonction de Bernstein.

On va tenter de majorer cet inf de façon explicite. Pour ceci, pour toutes matrices  $U^0$  et  $V^0$  et  $\delta > 0$  on définit  $\rho_{U^0, V^0, \delta}$  comme la loi  $\pi$  restreinte à l'ensemble  $\{(U, V) : \|U - U^0\| \leq \delta, \|V - V^0\| \leq \delta\}$ .

5) Démontrer que

$$\int R(N) \rho_{U^0, V^0, \delta}(\mathrm{d}N) \leq R(U^0 V^0) + \delta^2 K(\sqrt{K}\delta + c)^2.$$

6) Démontrer que

$$\mathcal{K}(\rho, \pi) = (m+p)K \log \left( \frac{1}{\delta} \sqrt{\frac{c}{K}} \right).$$

7) En déduire qu'il existe une constante (pouvant dépendre du choix de  $c$ )  $\mathcal{C}(c)$  telle que

$$R(\hat{M}_\lambda) \leq \mathcal{C}(c) \inf_{\|U^0\|, \|V^0\| \leq \sqrt{c/K}} \left[ R(U^0 V^0) + \frac{(m+p)K \log \left( \frac{cn}{(m+p)K} \right) + \log \left( \frac{2}{\varepsilon} \right)}{n} \right].$$

On pourra expliciter  $\mathcal{C}(c)$ .

8) Discuter la borne obtenue. En particulier, on pourra supposer qu'il existe effectivement  $U^0$  et  $V^0$  avec  $\|U^0\|, \|V^0\| \leq \sqrt{c/K}$  et  $M = U^0 V^0$ , et se concentrer sur la vitesse  $\frac{(m+p)K}{n}$ . Est-il possible de reconstruire correctement une matrice à  $m \times p$  entrées en n'observant que  $n$  entrées aléatoires, avec  $n \ll m, p$ ?

9) Question subsidiaire : comment implémenteriez-vous le calcul de  $\hat{M}_\lambda$  en pratique ?

10) Question encore plus subsidiaire : en pratique, on ne connaît pas  $K$ . Que proposeriez-vous ?

**EXERCICE 2.** Dans cet exercice, on va étendre des résultats du cours démontrés pour des variables bornées à des variables non bornées. Pour ceci, on commence par essayer d'étendre l'inégalité de Bernstein à des variables aléatoires non bornées.

1) Soit  $Z$  une variable aléatoire de loi exponentielle  $\mathcal{E}(\theta)$ . On pose  $f(\lambda) = \log \mathbb{E} e^{\lambda(Z - \mathbb{E}(Z))}$ .

(a) Rappeler une formule explicite pour  $f(\lambda)$  et son domaine de définition.

(b) Démontrer que pour tout  $u \in ]0, 1[$ ,  $-\log(1-u) - u \leq \frac{u^2}{2(1-u)}$  et en déduire que

$$\log \mathbb{E} e^{\lambda Z} \leq \frac{\mathrm{Var}(Z)\lambda^2}{2(1-c\lambda)}$$

pour une constante  $c$  que l'on précisera.

Par analogie, on dit que  $Z'$  est sous-exponentielle avec les paramètres  $(v, c)$  ssi pour tout  $\lambda \in ]-1/c, 1/c[$ ,

$$\log \mathbb{E} e^{\lambda Z'} \leq \frac{v\lambda^2}{2(1-c\lambda)}.$$

(c) Soient  $Z$  et  $Z'$  deux variables sous-exponentielles de paramètres respectifs  $(v, c)$  et  $(v', c)$ . Démontrer que  $Z+Z'$  est sous-exponentielle de paramètres  $(v+v', c)$ . Démontrer que  $\alpha Z$ , pour  $\alpha \in \mathbb{R}$ , est sous-exponentielle  $(\alpha^2 v, c)$ .

(d) Soit  $Z$  une variable aléatoire  $\mathcal{N}(0, \sigma^2)$ . Démontrer que  $Z^2$  est sous-exponentielle de paramètres  $(2\sigma^2, 2)$ .

2) Soient  $Z_1, \dots, Z_n$  des variables aléatoires indépendantes, centrées, sous-exponentielles de paramètre  $(v, c)$ . Démontrer que pour tout  $\lambda \in ]-n/c, n/c[$  on a

$$\mathbb{E} e^{\frac{\lambda}{n} \sum_{i=1}^n Z_i} \leq e^{\frac{v\lambda^2}{2n(1-c\frac{\lambda}{n})}}.$$

3) On suppose que l'on observe  $(X_1, Y_1), \dots, (X_n, Y_n)$  i.i.d de loi  $P$ . On suppose que l'on a  $f_1, \dots, f_M$  des fonctions  $\mathcal{X} \rightarrow \mathbb{R}$ , un ensemble  $\Theta \subset \mathbb{R}^M$  et une fonction de perte  $\ell$  (pas forcément bornée). On définit pour  $\theta \in \Theta$  la fonction  $f_\theta(\cdot) = \sum_{i=1}^M \theta_i f_i(\cdot)$  et on suppose que pour tout  $\theta \in \Theta$ ,  $\ell(Y_i, f_\theta(X_i))$  est une variable sous-exponentielle de paramètres  $(v, c)$ .

(a) En suivant la preuve du cours, démontrer que, pour tout  $\varepsilon \in ]0, 1[$  on a

$$\mathbb{P} \left\{ \int R(f_\theta) \pi_{\exp(-\lambda r_n)}(d\theta) \leq \inf_{\rho} \left[ \int R(f_\theta) \rho(d\theta) + \frac{v\lambda}{n(1 - c\frac{\lambda}{n})} + 2 \frac{\mathcal{K}(\rho, \pi) + \log\left(\frac{2}{\varepsilon}\right)}{\lambda} \right] \right\}.$$

(b) Comparer avec le résultat du cours pour les variables bornées (par exemple, en appliquant ce théorème au cas de la MS-agrégation).