

Statistiques en grande dimension

Christophe Giraud^{1,2}

- (1) Université Paris-Sud
- (2) Ecole Polytechnique

M2 Data Science & ISG

Objectifs du cours

- ❶ expliquer le cadre conceptuel de la stats en grande dimension (dans un contexte simple)
- ❷ expliciter comment jouent diverses quantités sur la difficulté stat d'un problème
- ❸ donner les clés pour comprendre la littérature scientifique en stats
- ❹ acquérir les outils mathématiques basiques du domaine

→ cours sur les "fondements mathématiques" mais axé sur la compréhension plutôt que sur les maths:

- pas de preuves longues
- des petits calculs pour comprendre les choses intuitivement
- pratique par des exos

Thématiques du cours

- ① Contrôle des fausses découvertes: tests multiples
- ② Fléau de la dimension: recherche de structures
- ③ Concept: sélection de modèle
- ④ Compromis algorithmique: convexification
- ⑤ Tirer partie de corrélations: faible rang

Documents

Documents

- Le poly
- Le site web du cours (avec les slides en ligne la veille)

<http://datascience-x-master-paris-saclay.fr/catalogue/statistique-en-grande-dimension/>

- Correction de certains exos (en cours d'écriture):

<http://high-dimensional-statistics.wikidot.com>

Cours de M2...



- il faut travailler le cours
- il faut s'entraider

Evaluation

Etape 1

- ➊ **s'enroller sur le site web** (sinon pas de note et pas d'infos sur le cours)
- ➋ Pour ISG: m'écrire d'ici ce soir pour qu'on vous crée des comptes

Etape 2

Examen écrit de 3h fin janvier

Pour ISG

Mini-projet sur la classification supervisée (février)

Organisation du cours

- 1 Fausses découvertes et tests multiples
- 2 Fléau de la dimension et adaptation aux structures
- 3 Sélection de modèles
- 4 Convexification
- 5 Structures complexes et sélection d'estimateurs
- 6 Faible rang
- 7 Faible rang et sparsité
- 8 Classification supervisée (ISG)
- 9 Classification supervisée (ISG)
- 10 Classification supervisée (ISG)

False discoveries

Scientific and societal concern



Lack of reproducibility

The Economist

World politics Business & finance Economics Science & technology

Unreliable research

Trouble at the lab

Scientists like to think of science as self-correcting. To an alarming degree, it is not

Oct 19th 2013 | From the print edition

Timekeeper Like 22k Tweet

Systematic attempts to replicate widely cited priming experiments have failed

- Amgen could only replicate 6 of 53 studies they considered landmarks in basic cancer science
- HealthCare could only replicate about 25% of 67 seminal studies
- etc

What has gone wrong?

Main Flaws

- Misusage of Statistics
- Publication Bias
- Publish or Perish




Back to the basics

Status of science

An hypothesis or theory can only be empirically tested.

Predictions are deduced from the theory and compared with the outcomes of experiments.

An hypothesis can be falsified or corroborated.



Karl Popper (1902-1994)

An historical example (1935)

The lady testing tea

A lady claims that by tasting a cup of tea made with milk she can discriminate whether the milk or the tea infusion was first added to the cup.


Experiment

8 cups are brought to the lady and she has to determine whether the milk or the tea was added first.

Test

Modeling: the success X_1, \dots, X_8 are i.i.d. with $\mathcal{B}(\theta)$ distribution.

Test: $\mathcal{H}_0 : \theta = 1/2$ versus $\mathcal{H}_1 : \theta > 1/2$



R.A. Fisher (1890-1962)

Hypothesis testing

Testing statistics

We reject the hypothesis \mathcal{H}_0 : "the lady cannot discriminate" if the outcome of the variable

$$\hat{S} = X_1 + \dots + X_8$$

is larger than some threshold s_{th} .

Choice of the threshold

We choose the threshold $s_{th} = s_{th}(\alpha)$ such that the probability to reject wrongly \mathcal{H}_0 is smaller than α (e.g. 5%)

$$\mathbb{P}_{1/2}(\hat{S} \geq s_{th}(\alpha)) = \alpha.$$

Reminder: under \mathcal{H}_0 the distribution of \hat{S} is $\text{Bin}(8, 1/2)$.

p -values

p -value

The p -value of the observation $\hat{S}(\omega_{obs})$, is the probability to observe \hat{S} larger than $\hat{S}(\omega_{obs})$ when \mathcal{H}_0 is true

$$\hat{p}(\omega_{obs}) = T_{1/2}(\hat{S}(\omega_{obs})), \quad \text{where } T_{1/2}(s) = \mathbb{P}(\text{Bin}(8, 1/2) \geq s).$$

Remark

Since

$$\hat{S}(\omega_{obs}) \geq s_{th}(\alpha) \iff \hat{p}(\omega_{obs}) \leq \alpha$$

we reject \mathcal{H}_0 if the p -value is smaller than α .

Foundations of science

Science is largely based on p -values. An hypothesis/theory is falsified or corroborated depending on the size of the p -value of the outcome of some experiment(s)/observation(s).

Where does-it go wrong?

Publications issues

- Publication bias
- Publishing pressure
- Lack of check: replication is not "recognized" and exponential growth of the number of scientific publications

Small sample size

Cost of adding individuals in experiments

New paradigm: era of Big Data

Collect data first → ask (many) questions later

Curse of dimensionality

Issue of multiple testing (one aspect of the curse of dimensionality)

Multiple testing

Analyse différentielle

Question

Est-ce que le niveau d'expression d'un gène diffère entre une condition A et une condition B ?

Données issues d'une expérience

Conditions	Mesures
A	X_{A1}, \dots, X_{Ar}
B	X_{B1}, \dots, X_{Br}

Objectif

Différencier entre les 2 hypothèses

\mathcal{H}_0 : "la moyenne des X_{Ai} et des X_{Bi} sont les mêmes"

\mathcal{H}_1 : "la moyenne des X_{Ai} et des X_{Bi} sont différentes"

Exemple de test

$Y_i = X_{Ai} - X_{Bi}$ pour $i = 1, \dots, r$.

Rejet de \mathcal{H}_0 si

$$\hat{S} := \frac{|\bar{Y}|}{\sqrt{\hat{\sigma}^2/r}} \geq s = \text{seuil à fixer}$$

avec $\hat{\sigma}^2 = \overline{\text{var}}(Y)$

Choix du seuil pour contrôler le risque de rejeter \mathcal{H}_0 à tort

$$\mathbb{P}_{\mathcal{H}_0}(\hat{S} \geq s_\alpha) \leq \alpha$$

Test : $T = \mathbf{1}_{\hat{S} \geq s_\alpha}$


Modèle statistique

$$X_{Ai} \stackrel{i.i.d.}{\sim} \mathcal{N}(\mu_A, \sigma_A^2) \quad \text{and} \quad X_{Bi} \stackrel{i.i.d.}{\sim} \mathcal{N}(\mu_B, \sigma_B^2)$$

On a alors $\mathcal{H}_0 = \mu_A = \mu_B$.

Loi sous \mathcal{H}_0

$$\hat{S} = \frac{\bar{Y}}{\sqrt{\hat{\sigma}^2/r}} \stackrel{\mathcal{H}_0}{\sim} \mathcal{T}(r-1) \quad (\text{student à } r-1 \text{ degrés de liberté})$$



Choix du seuil s_α

On prend s_α tel que $\mathbb{P}(|\mathcal{T}(r-1)| \geq s_\alpha) = \alpha$

Exemple : analyse différentielle de 1 gène

Data

i	X_A	X_B	Y
1	4.01	4.09	-0.08
2	0.84	0.97	-0.12
3	4.45	3.92	-0.53
4	4.73	6.01	1.28
5	6.16	6.01	0.15
6	4.23	6.48	-2.26
7	4.70	5.85	-1.15
8	10.65	11.02	-0.37
9	2.02	4.18	-2.16
10	3.96	5.19	-1.23
mean	4.58	5.37	-0.80
std	2.60	2.55	0.96

Test

r	10
\bar{Y}	-0.80
$\sqrt{\hat{\sigma}^2}$	0.96
\hat{S}	2.62
p -value	0.03


p -value d'un test

Valeur de α pour laquelle le test change de réponse ($s_{\hat{p}} = \hat{S}$)

Si p -value $\leq \alpha$: $s_{\alpha} \leq \hat{S}$
le test rejette \mathcal{H}_0

Si p -value $> \alpha$: $s_{\alpha} > \hat{S}$
le test accepte \mathcal{H}_0

Genomic data



Whole Human Genome Microarray covering over 41,000 human genes and transcripts on a standard 1" x 3" glass slide format

High-dimensional data

we measure 41,000 gene expression levels simultaneously!

Blessing?

Des nouvelles perspectives médicales

Objet

Personnaliser les traitements anti-cancer en combinant données cliniques et génomiques

Moyens

RNAseq, puces CGH, etc

Questions


- Quelle prévision de survie?
- Quel “type” de cancer?
- Quel traitement adopter?
- etc

Blessing?

😊 we can sense thousands of variables on each "individual" : potentially we will be able to scan every variables that may influence the phenomenon under study.

😞 the signal might be blurred by the noise

Comparaison multiples : analyse différentielle de p gènes



Une puce microarray permet de comparer le niveau d'expression de milliers de gènes en même temps.

Résultat: liste de p -value classées par ordre croissant

gènes	p -value
2014	$< 10^{-16}$
1078	$6.66 \cdot 10^{-16}$
123	$2.66 \cdot 10^{-15}$
548	$1.02 \cdot 10^{-11}$
3645	$3.09 \cdot 10^{-10}$
\vdots	\vdots

Quels gènes sont statistiquement différentiellement exprimés?

Ceux qui ont une p -value $\leq 5\%$?

Quel contrôle du risque de déclarer à tort qu'un gène est différentiellement exprimé?

Procedure de Benjamini et Hocheberg

Procedure de Benjamini et Hocheberg:



- 1 On ordonne les p -value par ordre croissant

$$p(1) \leq p(2) \leq \dots \leq p(p)$$

- 2 Rejet de toutes les hypothèses $\mathcal{H}_0^{(i)}$ correspondant aux p -values $p(1), \dots, p(k)$ où

$$k = \operatorname{argmax} \{j : p(j) \leq \alpha j / p\}$$

Exemple : p -values



Exemple : comparaison avec Bonferroni ($\alpha = 5\%$)

